

1 Busca Heurística

Realize uma busca utilizando o algoritmo A* para encontrar o melhor caminho para chegar a **Bucharest** partindo de **Lugoj**. Construa a árvore de busca criada pela execução do algoritmo apresentando os valores de $f(n)$, $g(n)$ e $h(n)$ para cada nó. Utilize a heurística de distância em linha reta, que pode ser observada na tabela abaixo.

Desenhe uma árvore para cada expansão, mostrando como está a borda, da mesma forma que foi visto em sala.

Essa tarefa pode ser feita em uma ferramenta de desenho, ou até mesmo no papel, desde que seja digitalizada (foto) e convertida para PDF.

NÃO É NECESSÁRIO IMPLEMENTAR O ALGORITMO.






Figura 3.22 Valores de $hDLR$ — distâncias em linha reta para Bucareste.

Resposta:


(a) Estado inicial



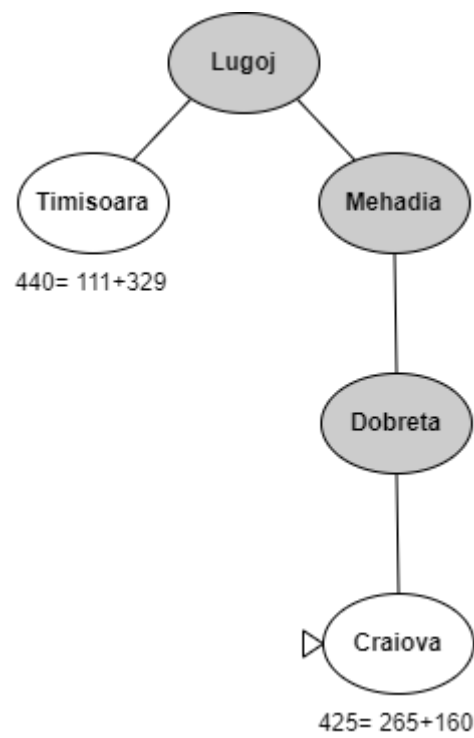
(b) Após expandir Lugoj



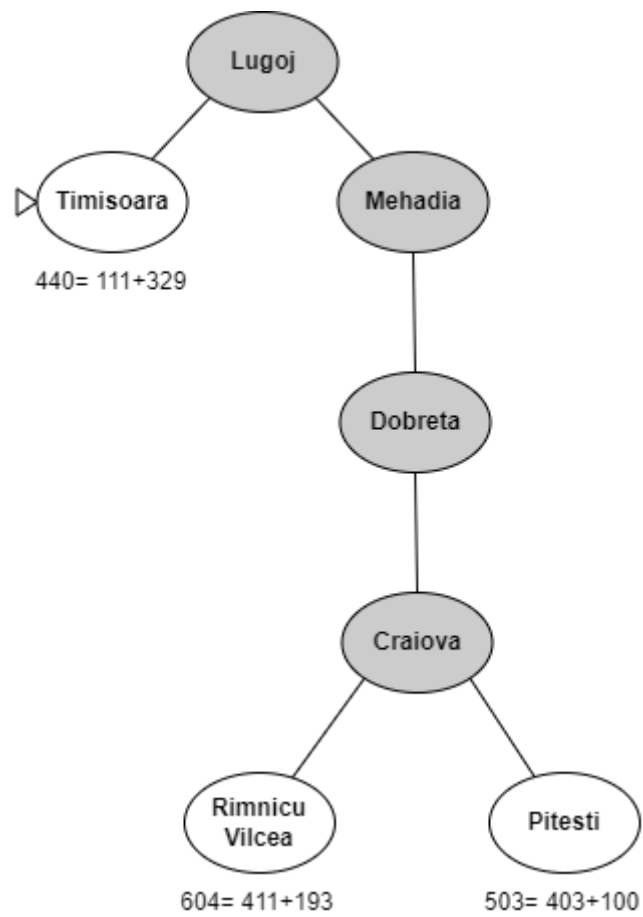
(c) Após expandir Mehadia



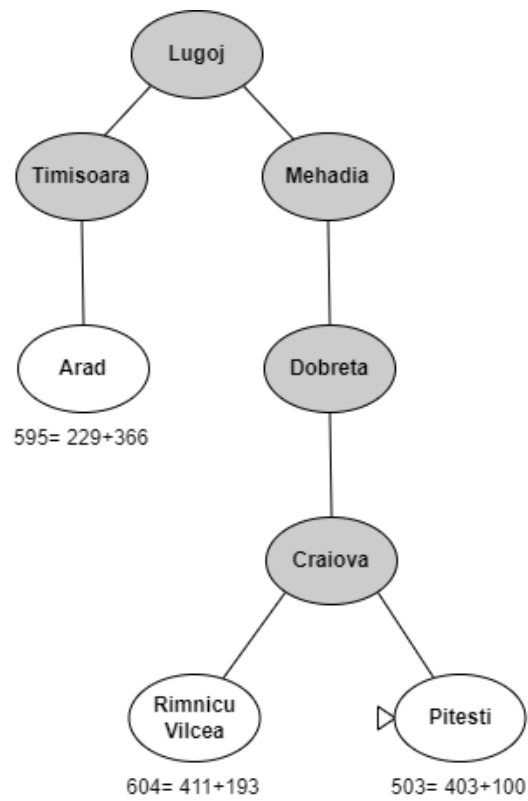
(d) Após expandir Dobreta



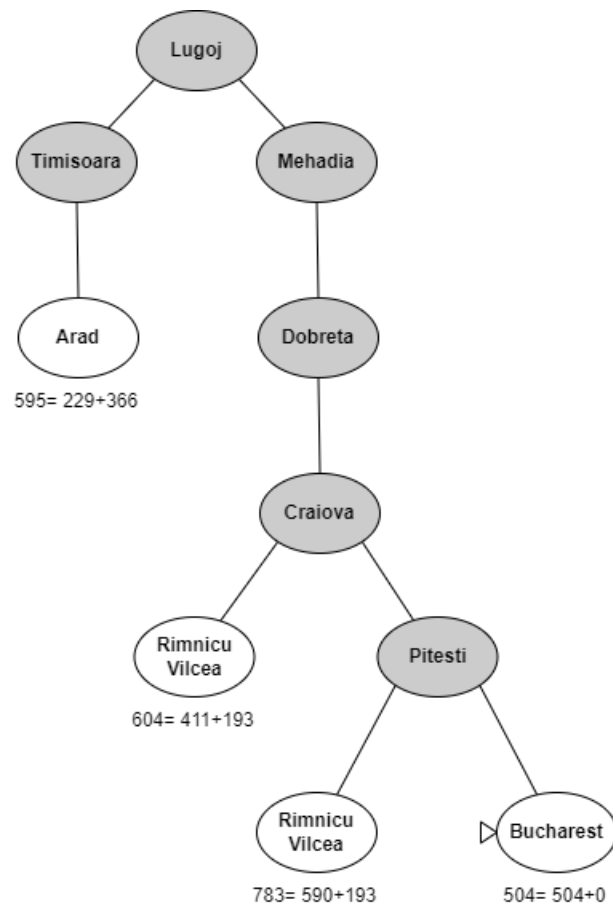
(e) Após expandir Craiova



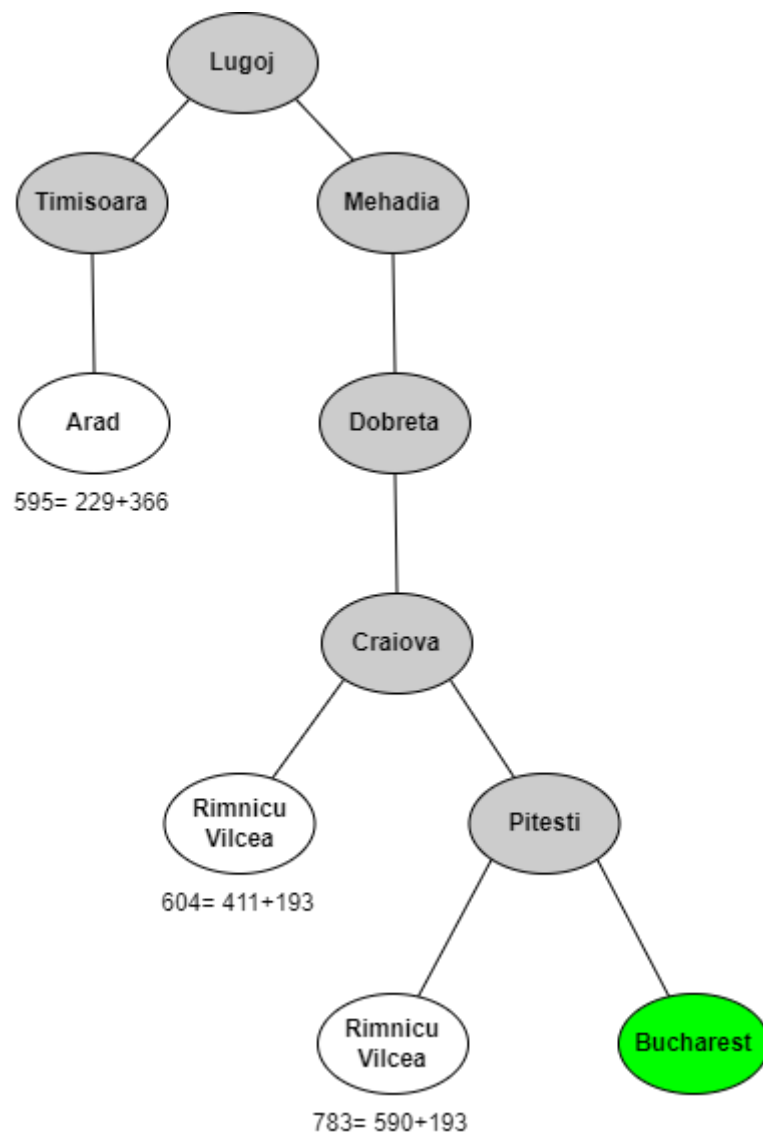
(f) Após expandir Timisoara



(g) Após expandir Pitesti



(h) Após expandir Bucharest



(i) Retorna resultado

2 Lógica

Verificar se o argumento lógico é válido.

Se as uvas caem, então a raposa as come
Se a raposa as come, então estão maduras
As uvas estão verdes ou caem
Logo:

A raposa come as uvas se e somente se as uvas caem

Dicas:

1. Transformar as afirmações para lógica:

p: as uvas caem

q: a raposa come as uvas

r: as uvas estão maduras

2. Transformar as sentenças para formar a base de conhecimento

R1: $p \rightarrow q$

R2: $q \rightarrow r$

R3: $\neg r \vee p$

3. Aplicar equivalências e regras de inferência para se obter o resultado esperado. Mostrar todos os passos e regras aplicadas. As equivalências e regras necessárias estão descritas abaixo.

Equivalência Implicação: $(\alpha \rightarrow \beta)$ equivale a $(\neg \alpha \vee \beta)$

Silogismo Hipotético: $\alpha \rightarrow \beta, \beta \rightarrow \gamma \vdash \alpha \rightarrow \gamma$

Conjunção: $\alpha, \beta \vdash \alpha \wedge \beta$

Equivalência Bicondicional: $(\alpha \leftrightarrow \beta)$ equivale a $(\alpha \rightarrow \beta) \wedge (\beta \rightarrow \alpha)$

Resposta:

Dado BC

- $R_1: p \rightarrow q$
- $R_2: q \rightarrow r$
- $R_3: \neg r \vee p$

Quer-se provar que

- $q \leftrightarrow p$

(a) Aplica-se equivalência Implicação em R_3

$$R_4: r \rightarrow p$$

Dado BC

- $R_1: p \rightarrow q$
- $R_2: q \rightarrow r$
- $R_3: \neg r \vee p$
- $R_4: r \rightarrow p$

Quer-se provar que

- $q \leftrightarrow p$

(b) Aplica-se Silogismo Hipotético em R_2 e R_4

$$R_5: q \rightarrow p$$

Dado BC

- $R_1: p \rightarrow q$
- $R_2: q \rightarrow r$
- $R_3: \neg r \vee p$
- $R_4: r \rightarrow p$
- $R_5: q \rightarrow p$

Quer-se provar que

- $q \leftrightarrow p$

(c) Aplica-se Equivalência Bicondicional em R_5 e R_1

$$R_6: q \leftrightarrow p$$

Dado BC

- $R_1: p \rightarrow q$
- $R_2: q \rightarrow r$

- $R_3: \neg r \vee p$
- $R_4: r \rightarrow p$
- $R_5: q \rightarrow p$
- $R_6: q \leftrightarrow p$

3 Deep Learning

Seu gerente escutou em algum lugar o termo *Deep Learning*. Como ele não possui conhecimento técnico, mas precisa ter o mínimo para discutir os projetos, ele solicitou a você, seu Engenheiro de Inteligência Artificial, que elaborasse um texto sobre o assunto.

Pesquise e escreva um resumo de no mínimo duas páginas sobre Deep Learning. Neste texto devem estar descritos a história, algoritmos, cases/aplicações e as referências usadas.

Lembre-se que o texto deve ser escrito para que alguém com conhecimentos básicos em IA (como os que esta disciplina apresenta) possa entender

Obviamente o uso de Wikipedia, blogs e sítios não confiáveis é proibido.

Resposta:

Deep Learning (DL) ou aprendizado profundo é uma área da Inteligência Artificial (IA). Para entender o que realmente é *Deep Learning* primeiramente é necessário saber o que é aprendizado de máquina ou *Machine Learning* e Redes Neurais Artificiais.

Machine Learning (ML) é uma área da IA em que são usados algoritmos de programação para ensinar determinado computador a realizar alguma tarefa, através de conjunto de dados já existentes. Com esses dados são realizadas correlações em busca de padrões, gerando (treinando) modelos que podem ser generalizados para a realização de uma tarefa específica. Com um modelo treinado é possível utilizá-lo em novos dados diferentes dos que foram utilizados no treinamento.

O aprendizado de máquina pode ser dividido em:

- a) **Aprendizado supervisionado:** consiste em dados parametrizados ou rotulados, onde o algoritmo recebe um conjunto de dados já rotulados, ou seja, com uma saída esperada (correta) correspondente, e o programa aprende comparando a saída do modelo com a saída esperada.

- b) **Aprendizado não supervisionado:** consiste em dados não parametrizados ou rotulados, buscando encontrar semelhanças entre agrupamento de dados, criando clusters ou grupo de dados.


Existem diversas técnicas de ML como: programação lógica induzida, árvores de decisão, clustenziação, redes Bayesianas, *Deep Learning*, aprendizado por reforço entre outras.

Redes Neurais Artificiais (RNAs) são modelos de ML que tem como base as atividades das redes de neurônio biológicos, como o cérebro humano. Uma RNA é uma máquina desenvolvida para realização de algumas funções que o cérebro realiza, sendo frequentemente implementada através de programação em computadores ou por componentes eletrônicos.

- a) **Modelo de neurônio biológico:** um neurônio biológico é composto pelas seguintes partes:
- a. **Dendrites:** faz coleta de impulsos oriundos de outros neurônios;
 - b. **Corpo Celular:** responsável em processar os sinais recebidos pelas dendrites;
 - c. **Axônio:** encarregado pela multiplicação dos sinais;
 - d. **Sinapse:** conexão do axônio com a dendrite de outro.

Abaixo segue imagem que representa um neurônio biológico.

Figura 1 – Neurônio Biológico



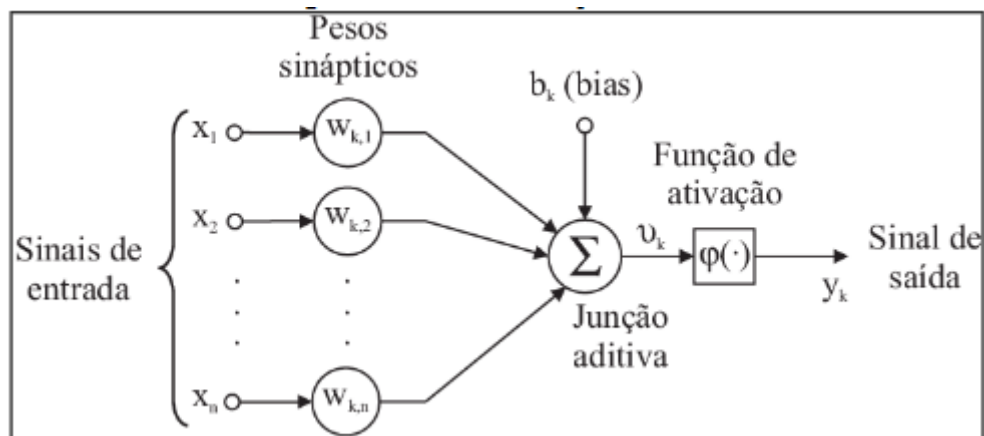
Fonte: Bianchini (2004)

- b) **Modelo de neurônio computacional:** o neurônio artificial possui características semelhantes ao modelo biológico, onde podem se identificar os seguintes elementos:

- a. **Conjunto de sinapses:** como no modelo biológico a sinapse é responsável em ligar um neurônio a outro. Neste caso, as sinapses formam um conjunto composto pelos sinais de entrada e pesos sinápticos, de forma que, cada sinal recebido será multiplicado pelo peso sináptico associado a ele. Desta maneira o neurônio irá tratar de forma diferente cada impulso recebido, atribuindo-lhe um valor;
- b. **Somador:** conhecido também como bias, é responsável em somar os sinais de entradas calculados com seus respectivos pesos;
- c. **Função de Ativação:** é usada para restringir a amplitude do sinal de saída do neurônio.

Abaixo segue representação gráfica do neurônio computacional

Figura 2 – Neurônio Computacional

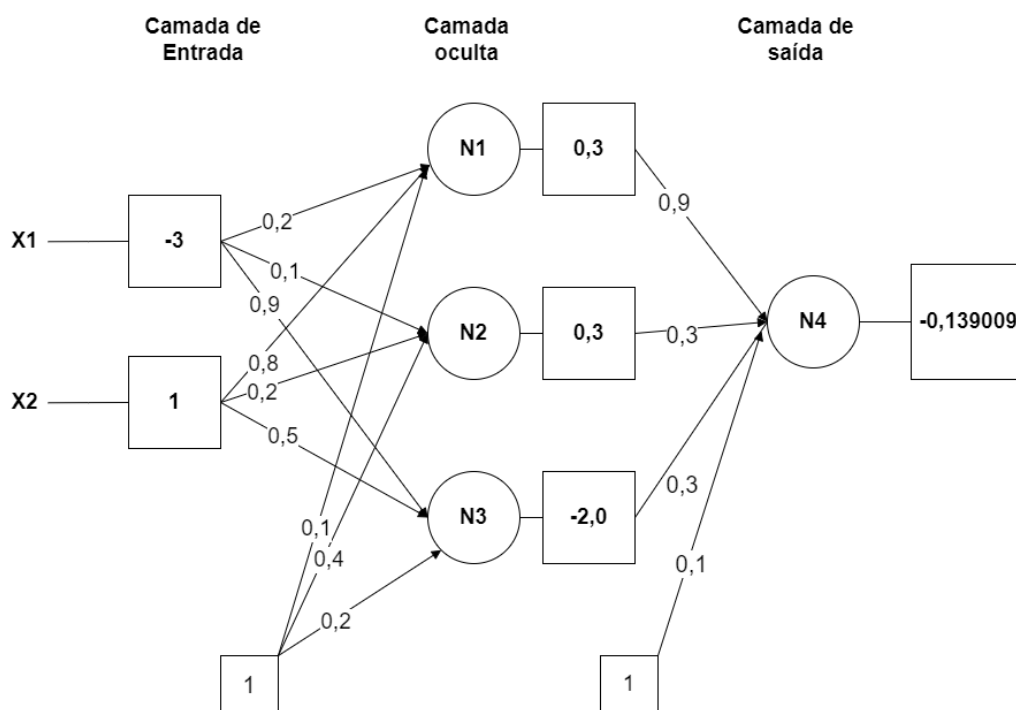


Fonte: Bianchini (2004)

As Redes Neurais Artificiais são constituídas por neurônios computacionais separados por camadas fazendo o processamento de informações, sendo conectados com a utilização de pesos sinápticos, transformando-se em sistemas adaptados para modificarem sua própria estrutura através de informações que surgem na rede durante o aprendizado.

É possível ter uma ou mais camadas de neurônios formando uma rede neural, onde o sinal de saída de um neurônio pode servir como sinal de entrada para outro, quando uma rede neural possui poucas camadas ela é dita como tendo arquitetura rasa (*shallow*), segue abaixo imagem de exemplo de arquitetura rasa, onde cada circunferência representa um bias junto com a função de ativação, cada valor na linha o peso sináptico e cada quadrilátero sinais de entrada ou saída.


Figura 3 – Arquitetura *Shallow*



Fonte: O autor (2022)

Quando uma rede neural possui muitas camadas entre a camada de entrada e saída, esta é chamada de rede com arquitetura profunda (*Deep*), que é a arquitetura usada em *Deep Learning*. A imagem abaixo ilustra exemplo de arquitetura profunda.

Figura 4 – Arquitetura *Deep*



Fonte: Ponti e Costa (2017)

O Aprendizado Profundo ou *Deep Learning* (DL) é uma área da Inteligência artificial que segue basicamente os mesmos princípios do ML, diferenciando apenas na função $f(.)$, onde as técnicas que utilizam DL aprendem a função a partir da composição de funções. Ao contrário das técnicas que não utilizam DL, que buscam uma única função a partir de um grupo de parâmetro gerando o resultado desejado.

Deep Learning surgiu como paradigma que busca tratar a dificuldade de arquiteturas utilizadas com frequência, as RNAs ou máquinas de vetores de suporte (SVM, do inglês *Support Vector Machine*), que possuem grande dimensão de dados, sendo mais difundido quanto maior a dimensionalidade.

Atualmente o DL está sendo utilizado em diversas áreas de estudo como: reconhecimento facial, reconhecimento de imagens e áudio, de caracteres, entre outras. Segue abaixo alguns casos de aplicação:

- **técnicas de DL na área da saúde:**

- **Predição de Mortalidade em Unidades de Terapia Intensiva:** Previsão de risco de morte para decisões terapêuticas eficientes. Através de Rede Neural Convolucional (CNN, do inglês *Convolutional Neural Network*), contendo cinco funções e nove camadas ocultas;
- **Deteção de Convulsões Epiléticas em Eletroencefalogramas:** classificação de sinais do Eletroencefalograma intracraniano (iEEG), para prognóstico e constatação de convulsões epiléticas em seres humanos. Foram analisados os ficheiros de iEEG, transformados em imagens e utilizando a rede CNN;
- **Classificação de Imagens Dermatoscópicas:** Identificação automática de melanoma em imagens dermatoscópicas. Por ser um problema de difícil solução, foi utilizado DL com CNN, obtendo 91,05% de acurácia;
- **Contagem Automática de Células em Imagens Obtidas por Microscópios:** contados automático de células para visualizar e analisar as imagens, com o propósito de facilitar diagnósticos e tratamento;

- **técnicas de DL no reconhecimento de imagem:**

- **Sistema Autônomo e Inteligente de Reconhecimento Facial para Autorização de Entrada de Pessoas em Ambientes Restritos:** Sistema que faz reconhecimento facial e de vida em pessoas autorizadas a entrar em ambientes restritos;
- **Reconhecimento de Espécies Florestais a partir de Imagens Digitais de Madeiras:** classificação de espécies florestais com base em imagens macro e microscópicas de madeira, com taxas de 98,73% de acurácia para imagens macroscópicas e 99,11% para imagens microscópicas;

- **Sistema para Reconhecimento de Expressões Faciais:** sistema de reconhecimento facial de emoções humanas, tais como raiva, medo, alegria, tristeza, desprezo, desgosto, surpresa e neutra, com precisão de 96,33%;
- **Detecção e Classificação de Sinalização Vertical de Trânsito em Cenários Complexos:** reconhecimento de sinalização vertical de trânsito, com imagem de placas de trânsitos em diversos ambientes;
- **técnicas de DL na mineração de dados:**
 - **Classificação de Fake News por Sumarização de Texto:** classificação de textos com base em propostas reais para a detecção de *fake News*, classificando palavras de um texto verdadeiro e comparando com um editado, com taxa de acurácia de 90%;
- **técnica de DL em Áudio/Texto:**
 - **Detecção de Ironia e Sarcasmo em Língua Portuguesa:** criação de sistema capaz de identificar ironia e sarcasmo na língua portuguesa, em postagens no *Twitter* obteve 98,65% de acurácia e 97,10% de precisão.
 - **Recuperação de Informações Musicais:** sistema para classificação de gêneros musicais usando CNN em diversos grupos de áudio e retirar características específica do áudio.

Por fim vale ressaltar que o *Deep Learning* possui aplicações amplamente variadas e seus resultados podem ser capazes de trazer mudanças significativas ao futuro da IA e da humanidade.

Referências

BIANCHINI, Ângelo R. **Arquitetura de redes neurais para o reconhecimento facial baseado no neocognitron**. 142 f. Dissertação (mestrado) – Universidade Federal de São Carlos, 2001. São Carlos: UFSar, 2004.

COPIN, Bem. **Inteligência Artificial**. Rio de Janeiro: LTC, 2017.

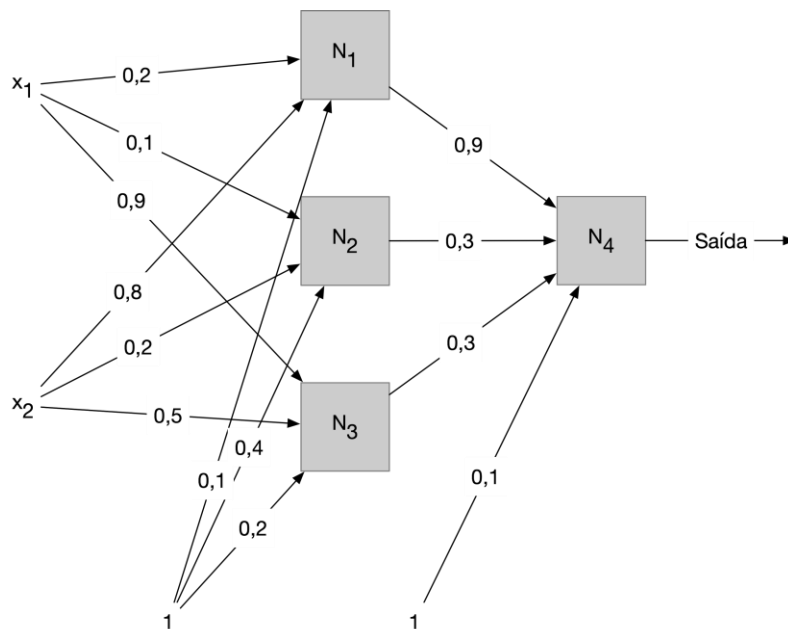
GRACE, Katja; SALVATIER, John; DAFOE, Allan; ZHANG, Baobao; EVANS, Owain. Viewpoint: When Will AI Exceed Human Performance? Evidence from AI Experts. **Journal of Artificial Intelligence Research**. *sl*, v. 62, p. 729 - 754, 2018.

PACHECO, César A. R.; PEREIRA, Natasha, S. Deep Learning Conceitos e Utilização nas Diversas Áreas do Conhecimento. **Ada Lovelance**. Goiás, v. 2, p. 34 - 49, 2018.

POTI, Moacir A.; COSTA, Gabriel B. P. da. **Tópicos em gerenciamento de dados e informações 2017**. Uberlândia: SBC, 2017.

4 Redes Neurais Artificiais

Seja a RNA da figura abaixo.



Dada a entrada $x_1=-3$, $x_2=1$, dê os valores de saída de todos os neurônios e indique qual é a saída da rede.

Os neurônios N_1 , N_2 e N_3 possuem função de ativação linear. Já N_4 possui função de ativação tangente hiperbólica (pesquise a fórmula e aplique).

Resposta:

