




1



2

3

## Transfer Learning

- **Inception:** É uma CNN para classificação de imagens
- Antes as redes eram construídas como camadas de convolução cada vez mais profundas
- Inception é construída de forma mais complexa, voltada também em desempenho



Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

3

4

## Transfer Learning

- Tem-se várias arquiteturas famosas
  - <https://towardsdatascience.com/illustrated-10-cnn-architectures-95d78ace614d>
- **Oxford VGG** : [http://www.robots.ox.ac.uk/~vgg/research/very\\_deep/](http://www.robots.ox.ac.uk/~vgg/research/very_deep/)
- **Google Inception** : <https://github.com/tensorflow/models/tree/master/research/inception>
- **Microsoft ResNet** : <https://github.com/KaimingHe/deep-residual-networks>
- etc

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

4

5

## Transfer Learning

- <https://towardsdatascience.com/a-simple-guide-to-the-versions-of-the-inception-network-7fc52b863202>
- Inception v1: <https://arxiv.org/pdf/1409.4842v1.pdf>
  - Imagens podem precisar de kernels de tamanhos diferentes
  - Aplicar na mesma camada, em paralelo
- Inception v2 e v3: <https://arxiv.org/pdf/1512.00567v3.pdf>
  - Diminuir o tamanho da convolução (mais eficiente)
  - Uso de outros otimizadores
  - etc
- Inception v4, Inception-ResNet: <https://arxiv.org/pdf/1602.07261.pdf>
  - Simplificação das camadas
- Etc

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

5

6

## Transfer Learning

- O desenvolvimento dessas redes também foi impulsionado pelo ImageNet Challenge
  - ILSVRC : ImageNet Large Scale Visual Recognition Challenge
  - <http://www.image-net.org/challenges/LSVRC/>
  - ImageNet DataSet : grande banco de dados de imagens, com propósito de pesquisa em visão computacional
  - Até 2017
- Agora Kaggle (Google)
  - <https://www.kaggle.com/>
  - Comunidade de cientistas de dados
  - Kaggle Competitions

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

6

7

## Transfer Learning

- A construção dessas redes é muito complexa
- O treinamento é demorado (muitas GPUs, muito tempo de treinamento)
- O resultado é ótimo
- **Tem como usar uma dessas redes em meus projetos?**

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

7

8

## Transfer Learning

- **SIM!!!**
- Isso é Transfer Learning
- **Transfer Learning**
  - Usar um modelo pré-treinado sobre nossa base de dados
  - Congelar a rede (frozen)
  - Adaptar a saída para os nossos dados
    - Ex, função de ativação, número de classes, etc
- **Fine Tuning**
  - Congelar parte da rede
  - A outra parte treinar

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

8

9

## Transfer Learning

- Em que situação usar???
- Base GRANDE e muito DIFERENTE – Treinar Todo o Modelo
- Base GRANDE e PARECIDA – Usar **Fine Tuning**
- Base PEQUENA e muito DIFERENTE – Usar **Fine Tuning**
- Base PEQUENA e PARECIDA – **Transfer Learning**

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT


Tensorflow

9

10

## Transfer Learning

- Queremos usar a MobileNets
- <https://arxiv.org/pdf/1704.04861.pdf>



Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow


10

## 11

# Transfer Learning

## Em **Transfer Learning**

- Deve-se redefinir o topo: **Global Average Pooling + Dense**
- Congela-se o modelo base
- Treina-se as novas camadas de saída



Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow


11

## 12

## Fine Tuning.

➤ Em ***Fine Tuning***

- Deve-se redefinir o topo: **Global Average Pooling + Dense**
- Congela-se a PARTE SUPERIOR (mais geral) do modelo base
- Treina-se parte do modelo base e a nova saída



Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

12

13

## Laboratório

- Classificar uma base de gatos e cachorros
- Usar uma rede pré-treinada : MobileNets
- MobileNets suporta
  - Imagens 96x96, 128x128, 160x160, 192x192, 224x224
  - 1000 classes

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

13

14

## Gatos e Cachorros

- Importações

```
import os
import zipfile
import numpy as np
import tensorflow as tf
import matplotlib.pyplot as plt

from tqdm import tqdm_notebook
from tensorflow.keras.preprocessing.image import ImageDataGenerator

# plota os gráficos inline e salva no notebook
%matplotlib inline
```

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

14

15

## Gatos e Cachorros

- Obter a base de dados

```
!wget http://www.razer.net.br/datasets/cats_and_dogs_filtered.zip
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

15

16

## Gatos e Cachorros

- Descompactação da base

```
# descompactar a base
dataset_path = "./cats_and_dogs_filtered.zip"
zip_object = zipfile.ZipFile(file=dataset_path, mode="r")
zip_object.extractall("./")
zip_object.close()
```

```
..
└─ cats_and_dogs_filtered
   └─ train
      └─ validation
         └─ vectorize.py
            └─ sample_data
               └─ cats_and_dogs_filtered.zip
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

16



17

## Gatos e Cachorros

- Diretório de Treino e Teste

```
dataset_path_new = "./cats_and_dogs_filtered"
train_dir = os.path.join(dataset_path_new, "train")
test_dir = os.path.join(dataset_path_new, "validation")
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

17

18

## Gatos e Cachorros

- Carregar modelo pré-treinado: MobileNet

```
input_shape = (128, 128, 3) # tamanho da imagem entrada
base_model = tf.keras.applications.MobileNetV2(
    input_shape=input_shape,
    include_top=False,
    weights="imagenet")
base_model.summary()
```

- `include_top = False` : não vai carregar o final da rede, que deverá ser definida por nós

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

18

19

## Gatos e Cachorros

- Congelar modelo base

```
# Congelar modelo base
base_model.trainable = False
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

19

20

## Gatos e Cachorros

- Adicionar Cabeçalho Personalizado

```
# Adicionar cabeçalho personalizado
print(base_model.output.shape)

# reduzir a dimensionalidade (4 x 4 x 1280 = 20480 pesos para treinar!!)
# Global Average Pooling
global_average_layer = tf.keras.layers.GlobalAveragePooling2D()(base_model.output)

print(global_average_layer.shape)

prediction_layer = tf.keras.layers.Dense(units=1, activation="sigmoid")(global_average_layer)
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

20

21

## Gatos e Cachorros

### Definição do Modelo

```
# Definição do modelo (unir o base com o personalizado)
model = tf.keras.models.Model(base_model.input,
                              prediction_layer)
model.summary()
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

21

22

## Gatos e Cachorros

### Compilar o modelo

```
# compilar o modelo
# testar com o Adam também

model.compile(optimizer=tf.keras.optimizers.RMSprop(
    learning_rate=0.0001),
              loss="binary_crossentropy",
              metrics = ["accuracy"])
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

22

23

## Gatos e Cachorros

- Carregar as imagens

```
# carga das imagens
# Pré-processamento /255
data_gen_train = ImageDataGenerator(rescale=1/255.)
data_gen_test  = ImageDataGenerator(rescale=1/255.)

train_generator = data_gen_train.flow_from_directory(
    train_dir,
    target_size = (128,128),
    batch_size  = 128,
    class_mode  = "binary")

test_generator = data_gen_train.flow_from_directory(
    test_dir,
    target_size = (128,128),
    batch_size  = 128,
    class_mode  = "binary")
```

Prof. Dr. Razer A. N. R. Montañó - UFPR/SEPT

Tensorflow

23

24

## Gatos e Cachorros

- Treinar o modelo

```
# Treinar o modelo
EPOCHS = 5

r = model.fit(train_generator,
              epochs      = EPOCHS,
              validation_data = test_generator)
```

Prof. Dr. Razer A. N. R. Montañó - UFPR/SEPT

Tensorflow

24

25

## Gatos e Cachorros

■ Plotar a *Loss-function*

```
plt.plot(r.history["loss"], label="loss")
plt.plot(r.history["val_loss"], label="val_loss")
plt.xlabel("Épocas")
plt.ylabel("Loss")
plt.xticks( np.arange(0, EPOCHS, step=1) )
plt.legend()
```

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

25

26

## Gatos e Cachorros

■ Plotar a Acurácia

```
plt.plot(r.history["accuracy"], label="accuracy")
plt.plot(r.history["val_accuracy"], label="val_accuracy")
plt.xlabel("Épocas")
plt.ylabel("Acurácia")
plt.xticks( np.arange(0, EPOCHS, step=1) )
plt.legend()
```

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

26

27

## Gatos e Cachorros.

- Avaliar o Modelo

```
# Avaliação do Modelo
val_loss, val_accuracy = model.evaluate (test_generator)
print(val_accuracy)
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

27

28

## Fine Tuning: Gatos e Cachorros

- Efetuar o **Fine Tuning**: Congelar as camadas até a 100

```
# Efetuar o Fine Tuning
# Primeiro fazer o Transfer Learning
# Depois o Fine Tuning

# descongelar algumas camadas
base_model.trainable = True
len(base_model.layers)

# deixar o início da base
# congelar o final
fine_tuning_at = 100

for l in base_model.layers[:fine_tuning_at]:
    l.trainable = False
```

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

28

29

## Fine Tuning: Gatos e Cachorros

- Compilar e Treinar o Modelo (fine tuning)

```
#compilar o modelo
# testar com o Adam tb

model.compile(optimizer = tf.keras.optimizers.RMSprop(
                    learning_rate=0.0001),
              loss      = "binary_crossentropy",
              metrics   = ["accuracy"])

# Treinar o modelo
EPOCHS = 5
r = model.fit(train_generator,
              epochs = EPOCHS,
              validation_data = test_generator)
```

Prof. Dr. Razer A. N. R. Montaña - UFPR/SEPT

Tensorflow

29

30

## Fine Tuning: Gatos e Cachorros

- Plotar a evolução da *Loss-Function*

```
plt.plot(r.history["loss"], label="loss")
plt.plot(r.history["val_loss"], label="val_loss")
plt.xlabel("Épocas")
plt.ylabel("Loss")
plt.xticks( np.arange(0, EPOCHS, step=1) )
plt.legend()
```

Prof. Dr. Razer A. N. R. Montaña - UFPR/SEPT

Tensorflow

30

31

## Fine Tuning: Gatos e Cachorros

- Plotar a evolução da Acurácia

```
plt.plot(r.history["accuracy"], label="accuracy")
plt.plot(r.history["val_accuracy"], label="val_accuracy")
plt.xlabel("Épocas")
plt.ylabel("Acurácia")
plt.xticks(np.arange(0, EPOCHS, step=1) )
plt.legend()
```

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

31

32

## Fine Tuning: Gatos e Cachorros.

- Avaliação do Modelo

```
# Avaliação do Modelo
val_loss, val_accuracy = model.evaluate(test_generator)
print(val_accuracy)
```

Prof. Dr. Razer A. N. R. Montañó – UFPR/SEPT

Tensorflow

32



33

## EXERCÍCIO..

- Executar o exercício de Transfer Learning e Fine Tuning.

Prof. Dr. Razer A. N. R. Montaña – UFPR/SEPT

Tensorflow

33