UFPR - Universidade Federal do Paraná SEPT - Setor de Educação Profissional e Tecnológica

IAA - Especialização em Inteligência Artificial Aplicada

IAA013 - Big Data (Parte 3)

Prof. **João Eugenio** Marynowski — <u>jeugenio@ufpr.br</u>







Conteúdo Anterior

- Fundamentos de Big Data
 - Big Data, Data Lake e Data Science
- Map Reduce e Hadoop
 - Utilização da Sandbox/VM
 - Personalização de aplicações Map Reduce
- Data Engineering (Gerenciamento/Ferramentas para Big Data)
- NoSQL e NewSQL
- Dados em movimento Processamento de Streaming







Atividade 9 – Storm

- Enviar um arquivo PDF respondendo qual a diferença entre os dados manipulados por aplicações Hadoop e pelo Storm?
- Comente brevemente justificando e apresentando uma possível utilização do Storm.

???







Atividade 10 – Estudo de Caso

- Enviar um arquivo PDF contendo uma descrição breve (2 páginas) sobre a implementação de uma aplicação ou estudo de caso envolvendo Big Data e suas ferramentas (NoSQL/Streaming).
 - Caracterizar os dados e seus Vs, e sobre a modelagem
- Também preparar uma apresentação (5 min)

Faremos a Tarde!







Programa

- Fundamentos de Big Data
 - Big Data, Data Lake e Data Science
- Map Reduce e Hadoop
 - Utilização da Sandbox/VM
 - Personalização de aplicações Map Reduce
- Data Engineering (Gerenciamento/Ferramentas para Big Data)
 - NoSQL e NewSQL
 - Dados em movimento Processamento de Streaming







Hoje

Detalhes sórdidos e ruminar tudo isso aí!







Execução do Wordcount no Storm da HDP 2.1

- Start Ambari
 - http://127.0.0.1:8000 (Ambari, Enable)
- Start Storm
 - http://127.0.0.1:8080 (admin:admin) (Storm, Service Actions, Start)
- Storm UI
 - http://127.0.0.1:8744
- Submit an wordcount topology to Storm
 - storm jar /usr/lib/storm/contrib/storm-starter/storm-starter-0.9.1.2.1.1.0-385-jar-with-dependencies.jar storm.starter.WordCountTopology WordCount

Obs: storm jar storm*.jar <classe para executar> <nome da topologia>







Administração do Storm


- Listar topologias ativas
 - storm list
 - http://127.0.0.1:8744
- Sumário da topologia
 - http://127.0.0.1:8744 (clicar no nome da topologia)
- Detalhes dos Spout e Bolts
 - http://127.0.0.1:8744 (clicar nos spouts e bolts)
- Logs (de acordo com os executores/portas)
 - less /var/log/storm/worker-6700.log
 - tail -f /var/log/storm/worker-6701.log (Crt+C para sair)
- Finalizar
 - storm kill WordCount | http://127.0.0.1:8744 (Kill)







Topologia WordCount





```
TopologyBuilder builder = new TopologyBuilder();
builder.setSpout("spout", new RandomSentenceSpout(), 2);
builder.setBolt("split", new SplitSentence(), 3)
           .shuffleGrouping("spout");
builder.setBolt("count", new WordCount(), 2)
           .fieldsGrouping("split", new Fields("word"));
Config conf = new Config();
LocalCluster cluster = new LocalCluster();
cluster.submitTopology(args[0], conf,
builder.createTopology());
```







Detalhes sórdidos...







```
TopologyBuilder builder = new TopologyBuilder();
builder.setSpout("spout", new RandomSentenceSpout(), 2);
builder.setBolt("split", new SplitSentence(), 3)
           .shuffleGrouping("spout");
builder.setBolt("count", new WordCount(), 2)
           .fieldsGrouping("split", new Fields("word"));
Config conf = new Config();
LocalCluster cluster = new LocalCluster();
cluster.submitTopology(args[0], conf,
builder.createTopology());
```







```
public static class RandomSentenceSpout extends BaseRichSpout {
    public RandomSentenceSpout(int ninterval) {
      interval = ninterval;
    public void nextTuple() {
      Utils.sleep(interval);
      String[] sentences = new String[]{"the cow jumped over the
moon", "an apple a day keeps the doctor away", "four score and seven
years ago", "snow white and the seven dwarfs", "i am at two with
nature"};
      String sentence = sentences[ rand.nextInt(sentences.length)];
      collector.emit(new Values(sentence));
    public void declareOutputFields(OutputFieldsDeclarer declarer) {
      declarer.declare(new Fields("word"));
```







```
TopologyBuilder builder = new TopologyBuilder();
builder.setSpout("spout", new RandomSentenceSpout(), 2);
builder.setBolt("split", new SplitSentence(), 3)
           .shuffleGrouping("spout");
builder.setBolt("count", new WordCount(), 2)
           .fieldsGrouping("split", new Fields("word"));
Config conf = new Config();
LocalCluster cluster = new LocalCluster();
cluster.submitTopology(args[0], conf,
builder.createTopology());
```







```
public static class SplitSentence extends ShellBolt
implements IRichBolt {
   public SplitSentence() {
      super("python", "splitsentence.py");
   }
}
```

```
class SplitSentenceBolt(storm.BasicBolt):
    def process(self, tup):
        words = tup.values[0].split(" ")
        for word in words:
        storm.emit([word])
```

```
public void declareOutputFields(OutputFieldsDeclarer
declarer) {
    declarer.declare(new Fields("word"));
}
```







```
TopologyBuilder builder = new TopologyBuilder();
builder.setSpout("spout", new RandomSentenceSpout(), 2);
builder.setBolt("split", new SplitSentence(), 3)
           .shuffleGrouping("spout");
builder.setBolt("count", new WordCount(), 2)
           .fieldsGrouping("split", new Fields("word"));
Config conf = new Config();
LocalCluster cluster = new LocalCluster();
cluster.submitTopology(args[0], conf,
builder.createTopology());
```







shuffleGrouping

- Distribui igualmente as tuplas entre os bolts
- "Hello world Hello" → "Hello"; "world"; "Hello"

fieldGrouping

- Agrupa, distribuindo as duplas de acordo com um campo
- "Hello world Hello" → "Hello" "Hello"; "world"

globalGrouping

- Envia as tuplas para um bolt específico
- "Hello world Hello" → "Hello" "world" "Hello"

allGrouping

- Envia todas as tuplas para todos bolts
- "Hello world Hello" → "Hello" "world" "Hello"; "Hello" "world" "Hello"; "Hello" "world" "Hello"







```
TopologyBuilder builder = new TopologyBuilder();
builder.setSpout("spout", new RandomSentenceSpout(), 2);
builder.setBolt("split", new SplitSentence(), 3)
           .shuffleGrouping("spout");
builder.setBolt("count", new WordCount(), 2)
           .fieldsGrouping("split", new Fields("word"));
Config conf = new Config();
LocalCluster cluster = new LocalCluster();
cluster.submitTopology(args[0], conf,
builder.createTopology());
```







```
TopologyBuilder builder = new TopologyBuilder();
builder.setSpout("spout", new RandomSentenceSpout(), 2);
builder.setBolt("split", new SplitSentence(), 3)
           .shuffleGrouping("spout");
builder.setBolt("count", new WordCount(), 2)
           .fieldsGrouping("split", new Fields("word"));
Config conf = new Config();
LocalCluster cluster = new LocalCluster();
cluster.submitTopology(args[0], conf,
builder.createTopology());
```







```
public static class WordCount extends BaseBasicBolt {
   Map<String, Integer> counts = new HashMap<String,
Integer>();
    public void execute (Tuple tuple, BasicOutputCollector
collector) {
      String word = tuple.getString(0);
      Integer count = counts.get(word);
      if (count == null) { count = 0; }
      count++;
      counts.put(word, count);
      collector.emit(new Values(word, count));
    public void declareOutputFields(OutputFieldsDeclarer
declarer) {
      declarer.declare(new Fields("word", "count"));
```

```
TopologyBuilder builder = new TopologyBuilder();
builder.setSpout("spout", new RandomSentenceSpout(), 2);
builder.setBolt("split", new SplitSentence(), 3)
           .shuffleGrouping("spout");
builder.setBolt("count", new WordCount(), 2)
           .fieldsGrouping("split", new Fields("word"));
Config conf = new Config();
LocalCluster cluster = new LocalCluster();
cluster.submitTopology(args[0], conf,
builder.createTopology());
```







WordCount Storm Topology

spout split count SplitSentence() RandomSentenceSpout() WordCount() A-L SplitSentence() WordCount() M-ZRandomSentenceSpout() SplitSentence()







Como faço a minha aplicação Storm?







Implementação e Implantação de uma Aplicação Storm

- Gerar o jar com a aplicação Storm no desktop
 - Seu ambiente de desenvolvimento (Sandbox) não tem JDK e fonte do Storm
- Enviar o jar para a sandbox ou cluster Storm
 - Winscp, scp ou [filebrowser]!:)
- Executar na sandbox ou cluster
- \$storm jar seu.jar seupacote.WordCount topologyname
- *** Equivalmente ao Hadoop!







- Compilar com: \$ mvn clean install -DskipTests=true
- ou configurar IDE para adicionar a opção skipTests=true na construção.
- * Netbeans: Properties, Actions, [Build project, Clean and Build project, Build with Dependencies], Set Properties: skipTests=true

* POM: <version> 0.9.1.2.1.1.0-385 </version>

https://archive.apache.org/dist/storm/apache-storm-0.9.1-incubating/







Componentes do Storm

Zookeeper

Zookeeper

Zookeeper

Supervisor

Supervisor

Supervisor

Supervisor

Supervisor



Storm Topology




Nimbus





Topologia WordCount





Storm Components

- Nimbus node (master, similar to JobTracker)
 - Uploads computations (jobs)
 - Distributes code
 - Launches workers
 - Monitors computation and reallocates workers
- ZooKeeper nodes
 - Coordinates the Storm cluster
- Supervisor nodes
 - Communicates with Nimbus through Zookeeper
 - Starts and stops workers according to signals from Nimbus







Ver os componentes no Ambari ...
Onde ficam os spouts e bolts... workers







Referencias para o Storm


- JAIN, A.; NALYA, A. Learning Storm. [s.l.] Packt Publishing Ltd., 2014.
- http://www.michael-noll.com/tutorials/running-multi-node-storm-cluster/
- http://br.hortonworks.com/hadoop-tutorial/processing-streaming-data-near-real-timeapache-storm/
- https://github.com/apache/storm/tree/master/examples/storm-starter
- **=** ...








Sistemas Big Data












Hadoop Cluster (Name Nodes /Resource Manager / Data Nodes /Spark Executors

https://www.cisco.com/c/en/us/td/docs/unified_computing/ucs/UCS_CVDs/Cisco_UCS_Integrated_Infrastructure_for_Big_Data_a nd_Analytics_with_Hortonworks_and_HDF.html



Sandbox HDP x2










Distributed File System (DFS) + MapReduce










Como Cria um Ambiente Distribuído?









Arquitetura do HDFS

FS/namespace/meta ops Secondary **HDFS** NameNode Client NameNode Namespace backup Heartbeats, balancing, replication etc.. DataNode DataNode DataNode DataNode DataNode Data \int serving \longrightarrow Nodes write to local disk






HADOOP 1.0

MapReduce

(cluster resource management & data processing)

HDFS

(redundant, reliable storage)










Hadoop 1 (HDFS, MapReduce)










Hadoop 2 (HDFS, YARN, MapReduce)









MapReduce e os Componentes do YARN


- Client submete um Job MapReduce
- HDFS NameNode, Secondary NameNode e DataNodes
 - Compartilha artefatos de recursos e Jobs
- Resource Manager (RM)
 - Controla o uso dos recursos
- Node Manager (NM)
 - Cria container p/ execução e monitora o seu uso
- Application Master (AM) (MapReduce JobTracker)
 - Coordena e gerencia Jobs e tarefas MR
 - Negocia com o RM para escalonar tarefas MR
 - Tarefas MR são iniciadas pelos NM(s)
- YarnChild (MapReduce TaskTracker)
 - Iniciados pelos NMs para executar tarefas MR







Sandbox HDP x2,...









Ecosistema Hadoop HDP 2.1

- Hue ecosistema Hadoop UI
- Beeswax Hive UI (interface BDR → SQL)
- Pig (PigLatin Bash/SQL)
- Hcatalog Catálogo de bases de dados
- Filebrowser HDFS UI
- Job Browser Hadoop Jobs
- Job Designer aplicações Hadoop
- Oozie designer Diversos sistemas/aplicações
- Ambari Gerência do cluster e aplicações http://<ip>:8080 (admin:admin)
- Hbase BD orientado a columa
- Knox Segurança
- Storm Stream ...







Adicionar um Slave com HDP

- Desligar as VMs e configure-as para modo Bridge (mesma rede), gere endereço MAC aleatório e religue as VMs
- Eleger uma máquina master e configurar os nomes adequadamente em todas as máquinas ajustando seus arquivos /etc/hosts, por exemplo:
 - 192.168.1.16 sandbox.hortonworks.com
 - 192.168.1.17 slave1.sandbox.hortonworks.com
- Em cada slave, ativar o seu novo nome: hostname <nome slaves> e reiniciar agente: ambari-agent restart
- http://<server ip>:8080 (admin:admin)
 - Hosts, Actions, Add New Hosts, Target hosts
 - Perform manual registration... do not use SSH
 - Slaves já possuem ambari agent
 - Adicione os componentes [DataNode e NodeManager]

**Resolver os warnings conforme informado ajuda a eliminar os serviços em execução no slave e que não serão utilizados.

Comandos VI

- Não tem vim na Sandbox
- Vi
 - <esc> modo comando
 - i insere
 - a insere depois
 - s substitui
 - yy copia linha
 - p cola
 - dd apaga linha (d apaga caracter)
 - cw substitui palavra
 - wq salva e sai







- :8088 ResourceManager Web UI
 - nodes slaves ativos, senão reinicar NodeManager nos slaves
- :19888 jobhistory
 - quais máquinas participaram da execução (Job ID, Map | Reduce, task*, Node)

- Instalação Hadoop via Ambari
 - Ssh ou não








Componentes Extras







Componentes de Sistemas Big Data





STORAGE AND BEYOND





RAPACHE KARON A distributed streaming platform

Producers App App App DB Stream Kafka Connectors Cluster Processors DB App App App App Consumers

Apache Kafka

- https://kafka.apache.org
- Read and write streams of data like a messaging system
- Streaming data pipelines that reliably get data between systems or applications
- Streaming applications that transform or react to the streams of data
- Write scalable stream processing applications that react to events in realtime
- Store streams of data safely in a distributed, replicated, fault-tolerant cluster








Real-time Data Feeds APACHE KAFKA **Online Data Real-time Stream Processing Processing HBase** Storm SQL Hive Accumulo Streaming Search Ingest Slider Solr **YARN HDFS HDFS HDP 2.2 Data Lake HDP 2.2**







Stream Windowing










Tell me the count of tweets per time zone every 10 seconds



SELECT TimeZone, COUNT(*) AS Count
FROM TwitterStream TIMESTAMP BY CreatedAt
GROUP BY TimeZone, TumblingWindow(second, 10)








Every 5 seconds give me the count of tweets over the last 10 seconds





SELECT Topic, COUNT(*) AS TotalTweets
FROM TwitterStream TIMESTAMP BY CreatedAt
GROUP BY Topic, HoppingWindow(second, 10, 5)







Apache Cassandra


- http://cassandra.apache.org
- https://www.youtube.com/watch?v=5qEoEAfAer8
- Orientado à família de colunas
- Tempo real e aplicações transacionais (online)
- Leitura intensiva para BI de grande escala
- Google BigTable + Amazon Dynamo → Facebook Cassandra
 - 2008/2010 Apache Cassandra
- Nós Peer-to-peer simétricos
- Particionamento em todos nós (75k na Apple)
- Replicação customizada para garantir tolerância à falhas
- Projeto para leitura e escrita dinâmica (anywhere)
- Netflix, Adobe, Twitter, HP, IBM, Rackspace, Cisco,...
- Cassandra Query Language (CQL): SQL-like







Estatística e Aprendizado de Máquina



R + Hadoop = RHadoop












Spark

- http://spark.apache.org/
- Execução em memória (100x mais rápido que o Hadoop)
- Aplicações em Java, Scala, Python e Spark shell









Data Frame

```
df=spark.read.format("com.databricks.spark.csv")\
.option("header","true").option("delimiter","\t")\
.option("inferSchema","true")\ .load("Diarias utf8.csv");
df.count();
df.select("Nome Órgão Superior","Valor Pagamento").show();
df.filter(df["Nome Órgão Superior"]=="MINISTERIO DA CULTURA").count();
-- Verificar qual órgão teve maior soma de gastos.
df.groupBy("Nome Órgão Superior").sum("Valor Pagamento").show();
```







Spark WordCount em Python e Scala

- https://spark.apache.org/examples.html
- Python

```
file = spark.textFile("hdfs://...")
file.flatMap(line => line.split(" "))
.map(word => (word, 1))
.reduceByKey(_ + _)
```







Programming Guides

- Quick Start: a quick introduction to the Spark API; start here!
- RDD Programming Guide: overview of Spark basics RDDs (core but old API), accumulators, and broadcast variables
- <u>Spark SQL, Datasets, and DataFrames</u>: processing <u>structured data with relational</u> queries (newer API than RDDs)
- <u>Structured Streaming</u>: processing <u>structured data streams</u> with relation queries (using Datasets and DataFrames, newer API than DStreams)
- Spark Streaming: processing data streams using DStreams (old API)
- MLlib: applying machine learning algorithms
- **GraphX**: processing graphs
- SparkR: processing data with Spark in R
- PySpark: processing data with Spark in Python
- Spark SQL CLI: processing data with SQL on the command line







Spark refs

- https://spark.apache.org/docs/latest/index.html
- https://spark.apache.org/docs/latest/ml-guide.html

- https://www.kaggle.com/code/kkhandekar/apache-spark-beginnertutorial/notebook
- https://www.kaggle.com/code/tylerx/machine-learning-with-spark
- https://colab.research.google.com/#machine-learning-examples







Neo4J

- Banco de Dados orientado a Grafo, com suporte nativo
- ACID
- Schema
- Free
- Suporta replicação e distribuição
- Suporte a consultas em diversas linguagens de programação







Neo4J – Modelo de Dados

- Nó: representa e armazena uma entidade
 - Label
 - Equivalente a um tipo ou categoria
 - Propriedades
 - Coleção de chave : valor
- Relação: faz a ligação entre nós
 - Label
 - Propriedades
 - Coleção de chave : valor

create(Mauro: Usuario {Nome: 'Mauro', Cidade: 'Curitiba', Filhos: 'Sim'}) Create(Raquel:Usuario{No me:'Raquel', Cidade:'Prude ntopolis', Filhos: 'Sim'}), (Lorenzo:Usuario{Nome:'Lo renzo', Cidade: 'Curitiba ', Filhos:'Não'}), (Augusto: Usuario { Nome: 'A ugusto', Cidade:'Curitiba', F ilhos:'Não'})

Onde: Mauro: um nome local de variável Usuario: Label "tipo "o {chave: valor, ... } propriedades


Onde: Mauro: um nome local de variável Usuario: Label "tipo " { chave: valor, ... } propriedades







HDP 2.6



^{*} HDP 2.6 - Shows current Apache branches being used. Final component version subject to change based on Apache release process.

^{****} Apache Solr is available as an add-on product HDP Search.







^{**} Spark 1.6.3+ Spark 2.1-HDP 2.6 supports both Spark 1.6.3 and Spark 2.1 as GA.

^{***} Hive 2.1 is GA within HDP 2.6.

2ª CiDWeek - 30/04 à tarde - https://youtu.be/nFYMhG6jPHk B2W (Americanas, Submarino, Shoptime, SouBarato, Bit, Ame, Let's e Now)









2ª CiDWeek - 30/04 à tarde - https://youtu.be/nFYMhG6jPHk










2ª CiDWeek - 30/04 à tarde - https://youtu.be/nFYMhG6jPHk









Atividade 10 – Estudo de Caso

- Enviar um arquivo PDF contendo uma descrição breve (2 páginas) sobre a implementação de uma aplicação ou estudo de caso envolvendo big data e suas ferramentas (NoSQL/Streaming).
 - Caracterizar os dados e seus Vs, e sobre a modelagem

Apresentação (5 min)









IAA013 - Big Data

- Fundamentos de Big Data
 - Data Lake e Data Science
- Map Reduce e Hadoop
 - Utilização da Sandbox/VM
 - Personalização de aplicações Map Reduce
- Data Engineering (Gerenciamento/Ferramentas para Big Data)
- NoSQL e NewSQL
- Dados em movimento Processamento de Streaming





