Exercício 3: Visualizando dados da coorte TCGA-LIHC

Professor: Mauro Castro

Estudante: Clístenes Grizafis Bento

Para responder a questão abaixo, considere o conjunto de dados disponível no seguinte endereço da internet:

https://github.com/csgroen/RTN_example_TCGA_LIHC

Este conjunto de dados foi pré-processado a partir do estudo TCGA et al. (2017), que descreve uma coorte de câncer de fígado. Neste conjunto de dados está incluindo uma matriz de valores numéricos e metadados correspondentes, disponibilizado em formato .RData no arquivo:

"tcgaLIHCdata_preprocessed.RData"

Faça o download do arquivo .RData, e observe o tipo de objeto carregado no **RStudio**. Trata-se de um objeto da classe SummarizedExperiment, que representa um "container", contendo uma matriz numérica juntamente com os metadados. Extraia a matriz de dados numéricos do objeto SummarizedExperiment e observe sua estrutura no **RStudio**: as colunas representam casos (n=371) e linhas representam variáveis moleculares (n=29885). Em seguida, selecione as 100 variáveis moleculares que mais contribuem para a distinção de casos (alternativamete, você pode selecionar features usando Coeficiente de Variação ou Abundância) e gere uma matriz filtrada contendo apenas as variáreis selecionadas. Por fim, execute uma análise de clusterização não-supervisionada, e visualize o resultado usando o pacote ComplexHeatmap.

FORMA DE ENVIO: Arquivo PDF

REFERÊNCIAS

In [4]:

The Cancer Genome Atlas Research Network (2017) Comprehensive and integrative genomic characterization of hepatocellular carcinoma. Cell, **169**, 1327–1341.e23.

Example of data preprocessing for RTN and RTNsurvival using the TCGA-LIHC cohort.

< https://github.com/csgroen/RTN_example_TCGA_LIHC >

Morgan M, Obenchain V, Hester J, Pagès H (2022). SummarizedExperiment: SummarizedExperiment container. R package version 1.26.1.

https://bioconductor.org/packages/SummarizedExperiment

```
'getOption("repos")' replaces Bioconductor standard repositories, see
'?repositories' for details
replacement repositories:
    CRAN: https://cran.r-project.org
Bioconductor version 3.10 (BiocManager 1.30.15), R 3.6.1 (2019-07-05)
Installing package(s) 'ComplexHeatmap'
Warning message in .inet_warning(msg):
"dependency 'rjson' is not available also installing the dependencies 'shape', 'circl
ize', 'GetoptLong', 'clue', 'GlobalOptions', 'png'
  There are binary versions available but the source versions are later:
         binary source needs_compilation
shape
          1.4.5 1.4.6
                                     FALSE
circlize 0.4.12 0.4.15
                                     FALSE
clue 0.3-59 0.3-64
                                      TRUE
png
        0.1-7 0.1-8
                                      TRUE
  Binaries will be installed
package 'GetoptLong' successfully unpacked and MD5 sums checked
package 'clue' successfully unpacked and MD5 sums checked
package 'GlobalOptions' successfully unpacked and MD5 sums checked
package 'png' successfully unpacked and MD5 sums checked
package 'ComplexHeatmap' successfully unpacked and MD5 sums checked
The downloaded binary packages are in
        C:\Users\clist\AppData\Local\Temp\RtmpGW05i4\downloaded_packages
installing the source packages 'shape', 'circlize'
Old packages: 'askpass', 'backports', 'BH', 'BiocManager', 'boot', 'broom',
  'callr', 'caret', 'class', 'cli', 'clipr', 'clue', 'cluster', 'codetools', 'colorspace', 'crayon', 'curl', 'data.table', 'DBI', 'dbplyr', 'dichromat', 'digest', 'dplyr', 'ellipsis', 'evaluate', 'fansi', 'forcats', 'foreach',
  'formatR', 'fs', 'generics', 'ggplot2', 'glmnet', 'glue', 'gower', 'gtable',
  'haven', 'hexbin', 'highr', 'hms', 'htmltools', 'htmlwidgets', 'httpuv',
  'httr', 'ipred', 'IRdisplay', 'IRkernel', 'iterators', 'jsonlite',
  'KernSmooth', 'knitr', 'labeling', 'later', 'lava', 'lubridate', 'magrittr',
  'maps', 'markdown', 'Matrix', 'matrixStats', 'mgcv', 'mime', 'ModelMetrics',
  'modelr', 'nlme', 'nnet', 'numDeriv', 'openssl', 'pbdZMQ', 'pillar',
  'pkgconfig', 'plyr', 'png', 'prettyunits', 'processx', 'prodlim', 'progress',
  'promises', 'ps', 'purrr', 'quantmod', 'R6', 'RColorBrewer', 'Rcpp', 'RCurl',
  'readr', 'readxl', 'recipes', 'repr', 'reprex', 'reshape2', 'rlang',
  'rmarkdown', 'rpart', 'rstudioapi', 'rvest', 'scales', 'selectr', 'shiny',
  'sourcetools', 'spatial', 'SQUAREM', 'stringi', 'stringr', 'survival', 'sys',
  'tibble', 'tidyr', 'tidyselect', 'tidyverse', 'timeDate', 'tinytex', 'TTR',
  'utf8', 'uuid', 'viridisLite', 'whisker', 'withr', 'xfun', 'xml2', 'xts',
  'yaml', 'zoo'
```

Importando pacotes necessários para análise

```
In [6]: library(ComplexHeatmap)
    library(SummarizedExperiment)
    library(circlize)
    library(RColorBrewer)
```

```
_____
ComplexHeatmap version 2.2.0
Bioconductor page: http://bioconductor.org/packages/ComplexHeatmap/
Github page: https://github.com/jokergoo/ComplexHeatmap
Documentation: http://jokergoo.github.io/ComplexHeatmap-reference
If you use it in published research, please cite:
Gu, Z. Complex heatmaps reveal patterns and correlations in multidimensional
 genomic data. Bioinformatics 2016.
_____
Warning message:
"package 'circlize' was built under R version 3.6.3"============================
======
circlize version 0.4.12
CRAN page: https://cran.r-project.org/package=circlize
Github page: https://github.com/jokergoo/circlize
Documentation: https://jokergoo.github.io/circlize_book/book/
If you use it in published research, please cite:
Gu, Z. circlize implements and enhances circular visualization
 in R. Bioinformatics 2014.
This message can be suppressed by:
  suppressPackageStartupMessages(library(circlize))
_____
```

Carregando dados

```
In [8]: load(file = "./data/tcgaLIHCdata_preprocessed.RData")
    class(tcgaLIHCdata)
```

'RangedSummarizedExperiment'

Verificando dimensões

```
In [9]: dim(tcgaLIHCdata)
```

1. 29885

2.371

Está de acordo com o enunciado

Extração de dados da matrix e metadados

```
In [10]: gexp <- assay(tcgaLIHCdata)
  rowAnnotation <- rowData(tcgaLIHCdata)
  colAnnotation <- colData(tcgaLIHCdata)</pre>
```

Verificando dados dos objetos

```
In [11]: class(gexp)
```

```
'matrix'
          class(rowAnnotation)
In [12]:
         'DFrame'
In [13]:
          class(colAnnotation)
         'DataFrame'
In [14]:
          gexp[1:3,1:4]
                              TCGA-DD-A3A3-
                                                TCGA-DD-A1EF-
                                                                 TCGA-ED-A627-
                                                                                  TCGA-DD-AACB-
                             01A-11R-A22L-07
                                              01A-11R-A131-07
                                                               01A-12R-A311-07
                                                                                 01A-11R-A41C-07
          ENSG0000000003
                                                                      18.8409124
                                  22.37358577
                                                   27.57565722
                                                                                      20.16986881
          ENSG00000000005
                                   0.04209836
                                                    0.01943315
                                                                      0.0246897
                                                                                        0.02132653
          ENSG0000000419
                                                   32.92042747
                                  13.36474791
                                                                      20.6326769
                                                                                      29.75572654
          rowAnnotation
In [15]:
          DataFrame with 29885 rows and 3 columns
                                                   SYMBOL
                                   ENSEMBL
                                                                   OG_ENSEMBL
                               <character>
                                              <character>
                                                                  <character>
          ENSG00000000003 ENSG00000000003
                                                   TSPAN6 ENSG00000000003.13
          ENSG00000000005 ENSG00000000005
                                                     TNMD ENSG00000000005.5
          ENSG00000000419 ENSG00000000419
                                                     DPM1 ENSG00000000419.11
                                                    SCYL3 ENSG00000000457.12
          ENSG00000000457 ENSG00000000457
          ENSG00000000460 ENSG00000000460
                                                 Clorf112 ENSG00000000460.15
          ENSG00000281883 ENSG00000281883
                                               AL512506.3 ENSG00000281883.1
          ENSG00000281887 ENSG00000281887 GIMAP1-GIMAP5 ENSG00000281887.1
          ENSG00000281903 ENSG00000281903
                                                LINC02246 ENSG00000281903.1
```

A estratégia adotada para redução de dados foi a de coeficiente da variação

SNORA50A

ENSG00000281910.1

LINC01144 ENSG00000281912.1

Atualizando nome das linhas usando rowAnnotation

```
In [16]: all(rownames(rowAnnotation)==rownames(gexp))
# [1] TRUE
rownames(gexp) <- rowAnnotation$SYMBOL</pre>
```

TRUE

Removendo genes com baixa contagem

ENSG00000281910 ENSG00000281910

ENSG00000281912 ENSG00000281912

```
idx <- rowSums(gexp!=0)/ncol(gexp)
gexp <- gexp[idx>0.3,]
dim(gexp)
```

```
    21547
    371
```

2.371

Filtrando matrix usando correlação com a variável "Tumor_Stage"

Removendo NAs usando colAnnotation

```
In [19]: colAnnotation_filt <- colAnnotation[,c("Tumor_Stage"), drop=F]
    colAnnotation_filt <- colAnnotation_filt[complete.cases(colAnnotation_filt),, drop=F]
    dim(colAnnotation_filt)

1. 347
    2. 1

In [20]: gexp_filt <- gexp_filt[ ,rownames(colAnnotation_filt)]
    dim(gexp_filt)

1. 100
    2. 347</pre>
```

Mudando escala dos dados

```
In [21]: x <- gexp_filt
x <- t(apply(x, 1, rank));x <- x/max(x)
x <- t(scale(t(x), center = TRUE, scale = F))
dim(x)

1. 100
2. 347</pre>
```

Aplicando clustenização

Ajustando nomes das colunas

```
In [22]: colAnnotation_filt$Tumor_Stage <- as.factor(colAnnotation_filt$Tumor_Stage)
levels(colAnnotation_filt$Tumor_Stage)</pre>
```

Ajustando esquema de cores

'1'
 '2'

```
In [24]: pal2 <- rev(brewer.pal(7,"RdYlBu"))
bks <- quantile(as.numeric(x), probs = seq(0,1, length.out = length(pal2)))
colors <- colorRamp2(breaks = bks, colors = pal2)</pre>
```

Executando clustenização e plotando heatmap usando ComplexHeatMap

